

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«ДОНСКОЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ЛАБОРАТОРНАЯ РАБОТА № 2

на тему «Обучение без учителя. Понижение размерности. Обнаружение аномалий. Кластеризация.»

Выполнил:

Студент Подшивалин Р.В.

Группа ___ИПБП41_____

Вариант: №18.

Проверил:

Дольников М.Г.

Ростов-на-Дону

2026 г.

СОДЕРЖАНИЕ

ЦЕЛИ И ЗАДАЧИ РАБОТЫ 3

1 ИССЛЕДОВАНИЕ МЕТОДОВ СНИЖЕНИЯ РАЗМЕРНОСТИ 3

1.1 Корреляционный анализ 3

1.2 Анализ попарных распределений 5

1.3 Метод главных компонент 6

1.4 Сингулярное разложение 6

1.5 Анализ независимых компонент 7

1.6 Сопоставление методов 8

1.7 Двумерные проекции и направления признаков 9

2 ИССЛЕДОВАНИЕ АЛГОРИТМОВ КЛАСТЕРИЗАЦИИ 9

2.1 Исходные данные и эталонная структура 9

2.2 Сравнение двенадцати алгоритмов 10

2.3 Выбор числа кластеров для K-Means 12

2.4 Иерархическая кластеризация 13

2.5 Выявление шума и выбросов 14

2.6 Количественная оценка качества 14

ВЫВОД 16

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ .....**Ошибка! Закладка не определена.**

ЦЕЛИ И ЗАДАЧИ РАБОТЫ

Цель работы — исследовать методы снижения размерности многомерных данных и сравнить алгоритмы кластеризации на данных варианта 18, определив наиболее подходящие методы по результатам визуального анализа и количественной оценки.

Для достижения цели я поставил следующие задачи: изучить исходные данные и оценить корреляционные зависимости; построить матрицу разброса; применить метод главных компонент (PCA — Principal Component Analysis), сингулярное разложение (SVD — Singular Value Decomposition) и анализ независимых компонент (ICA — Independent Component Analysis); оценить вклад компонент и построить двумерные проекции; исследовать 12 алгоритмов кластеризации; подобрать параметры и выявить шумовые наблюдения; сравнить полученные кластеры с эталонными метками и обосновать выбор лучшего метода.

В первой части я анализировал 222 наблюдения с пятью числовыми признаками a, b, c, d, e. Во второй части я исследовал 226 наблюдений по признакам a и b. Эталонные метки y я использовал только для визуализации и проверки результатов, не включая их в обучение моделей.

1 ИССЛЕДОВАНИЕ МЕТОДОВ СНИЖЕНИЯ РАЗМЕРНОСТИ

1.1 Корреляционный анализ

Сначала я вычислил матрицу коэффициентов линейной корреляции Пирсона для пяти признаков. Коэффициенты принимают значения от −1 до +1 и характеризуют направление и тесноту линейной связи между парами переменных.

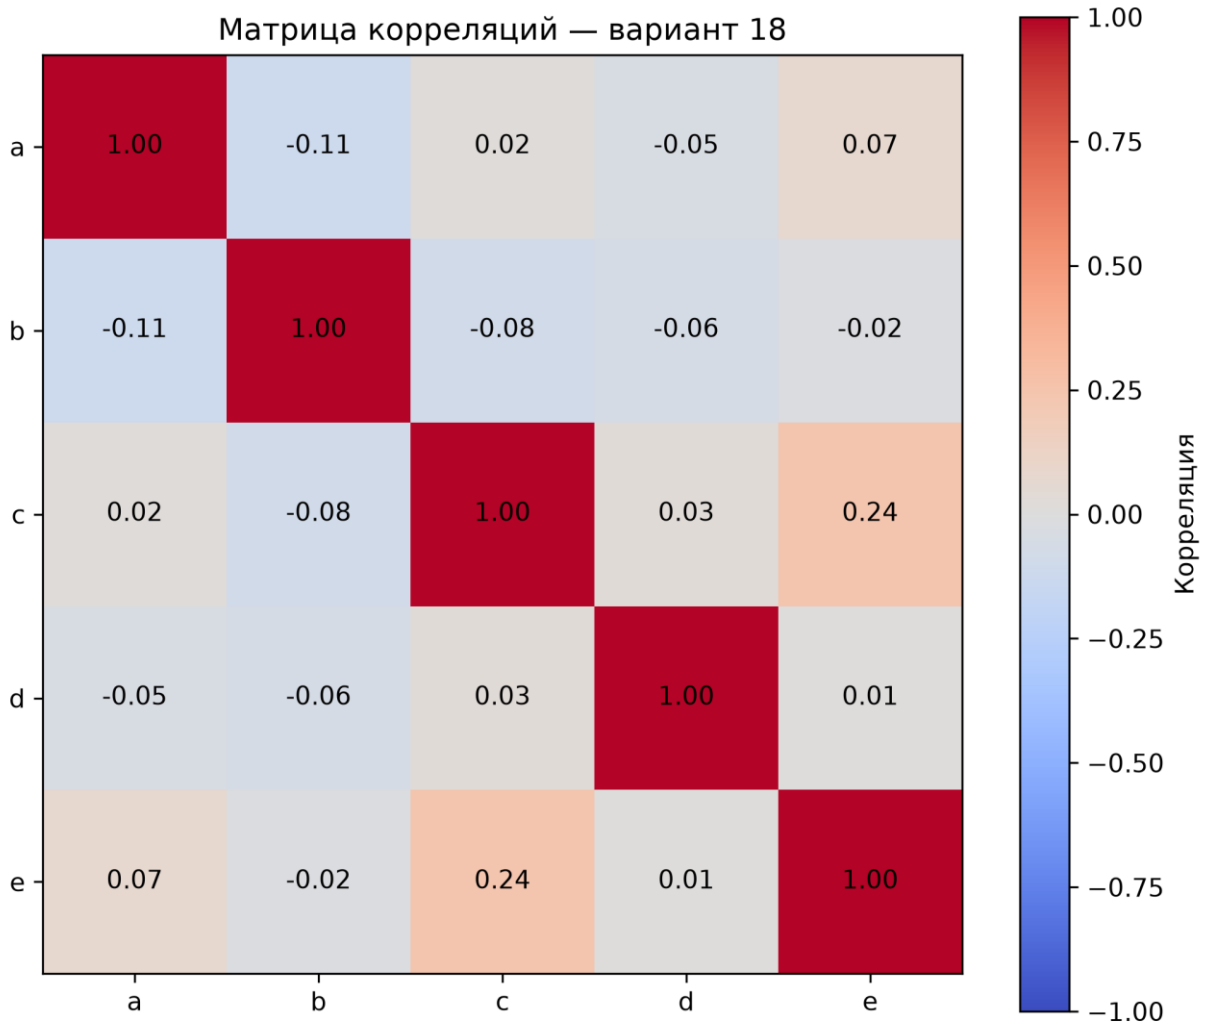


Рисунок 1 — Матрица корреляций признаков варианта 18

Матрицу я получил с помощью функции corr() библиотеки pandas и визуализировал цветовой картой Matplotlib. Рисунок необходим для оценки линейной избыточности признаков. Наибольшая внедиагональная корреляция наблюдается между c и e (0,237); остальные связи слабые. Поэтому я не выявил оснований исключать признаки только по линейной корреляции.

1.2 Анализ попарных распределений

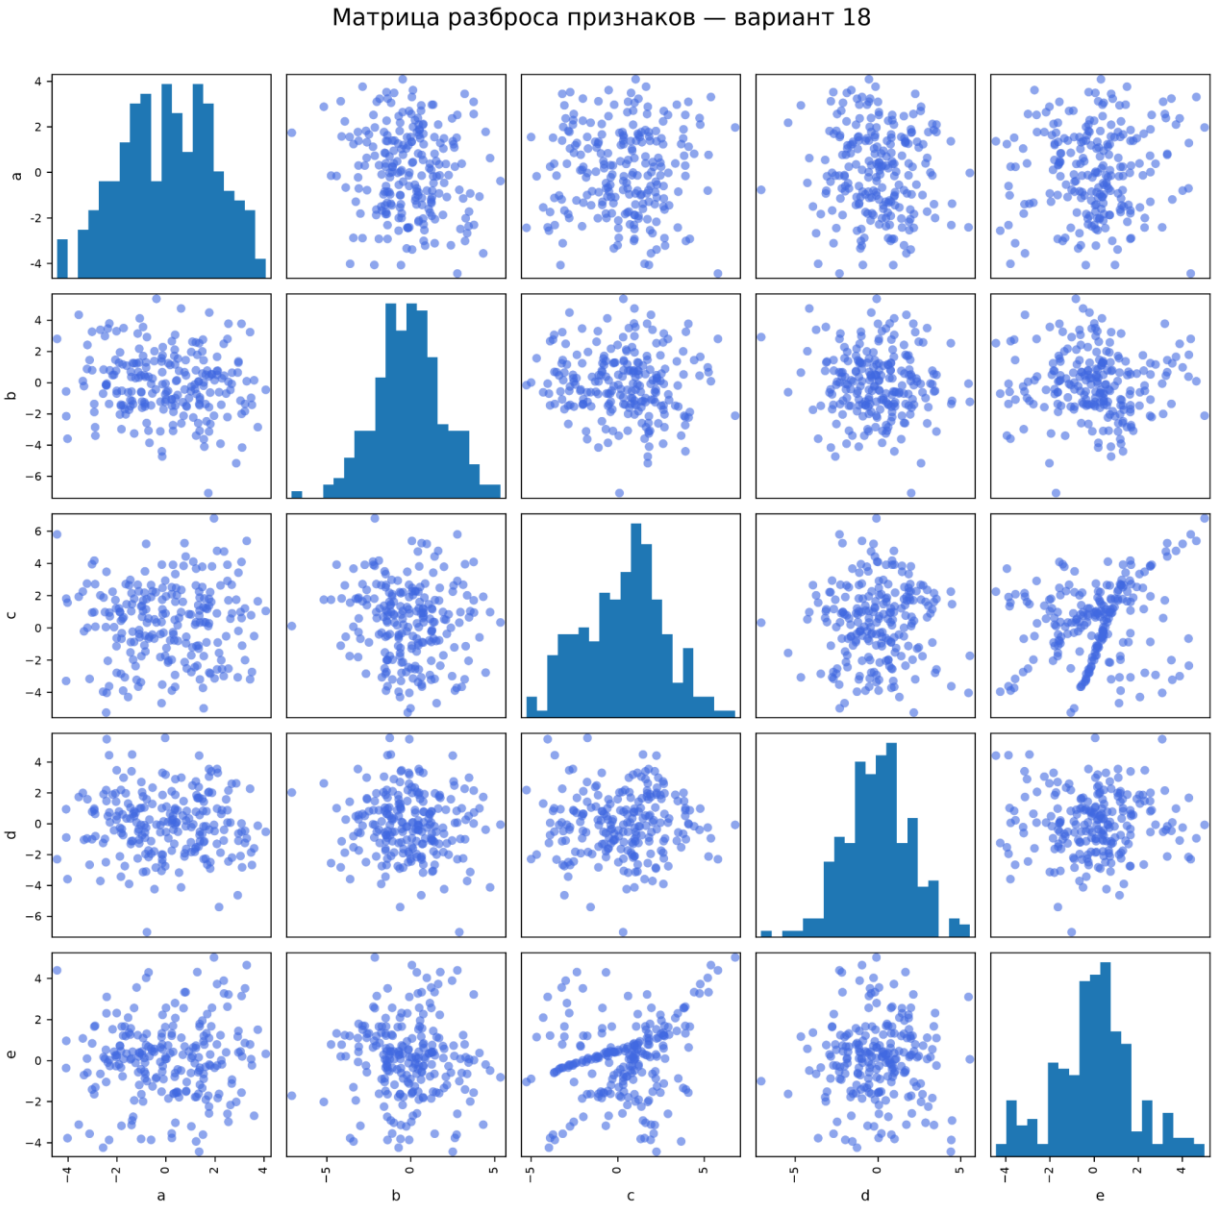


Рисунок 2 — Матрица разброса пяти признаков

Я построил матрицу функцией scatter_matrix(): вне диагонали представлены диаграммы рассеяния пар признаков, на диагонали — гистограммы. Она позволяет обнаружить нелинейные зависимости, которые не отражает корреляция Пирсона. Для пары c и e я заметил выраженные линии и ветвления, несмотря на умеренную линейную корреляцию.

1.3 Метод главных компонент

Для анализа главных компонент я предварительно стандартизировал данные и применил PCA. Метод формирует взаимно ортогональные направления, упорядоченные по убыванию объяснённой дисперсии.

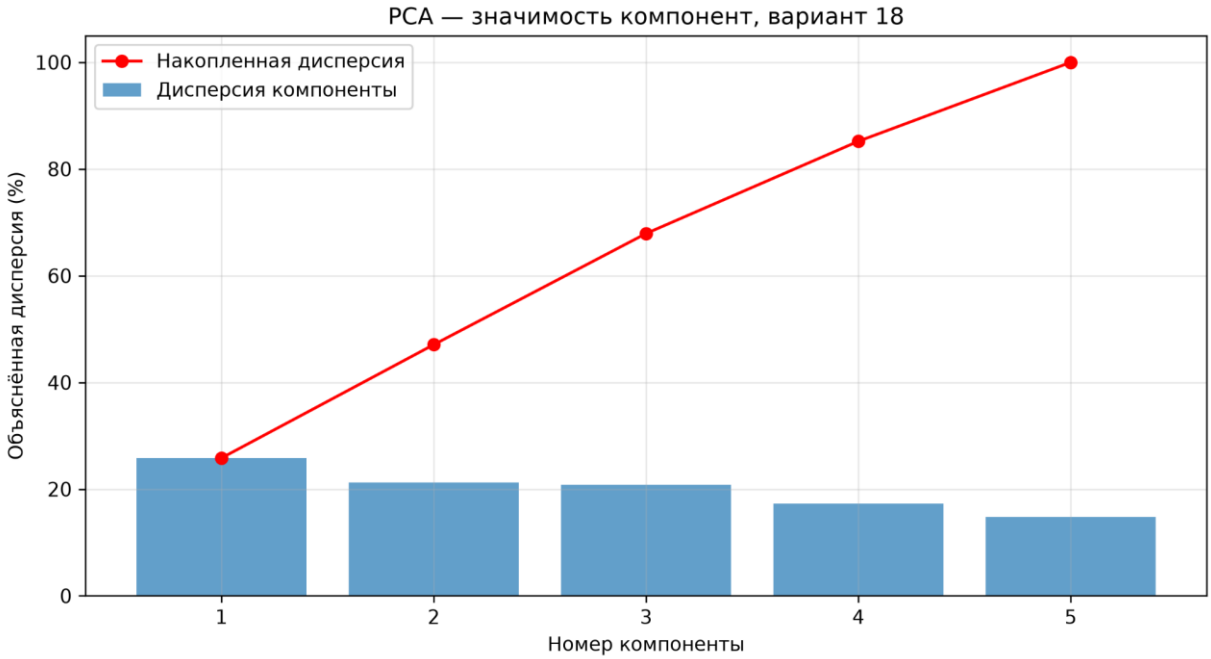


Рисунок 3 — Объяснённая и накопленная дисперсия PCA

Я построил диаграмму по атрибуту explained_variance_ratio_ модели PCA. Столбцы отражают долю объяснённой дисперсии каждой компоненты, красная линия — накопленную долю. Первые две компоненты объясняют 47,08 %, три — 67,91 %, четыре — 85,21 %. Следовательно, для сохранения не менее 80 % дисперсии мне потребовались четыре компоненты.

1.4 Сингулярное разложение

Я выполнил SVD над той же стандартизированной матрицей. Доли дисперсии рассчитал по квадратам сингулярных чисел, нормированным на их сумму.

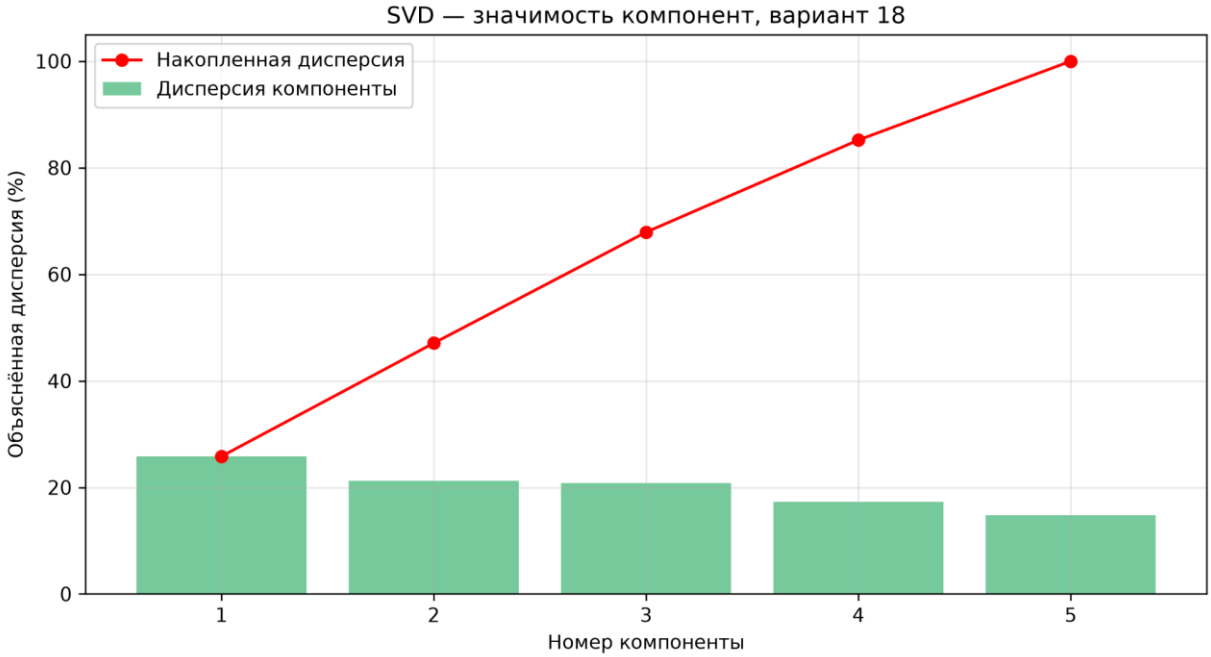


Рисунок 4 — Объяснённая и накопленная дисперсия SVD

Диаграмму я построил по сингулярным числам, полученным функцией numpy.linalg.svd(). Она позволяет оценить вклад направлений разложения и сопоставить его с PCA. Значения совпали, поскольку разложение выполнено для одной и той же центрированной матрицы признаков.

1.5 Анализ независимых компонент

Для поиска статистически независимых скрытых источников я применил ICA с реализацией FastICA. Я последовательно изменял количество компонент от одной до пяти и оценивал точность восстановления исходных данных.

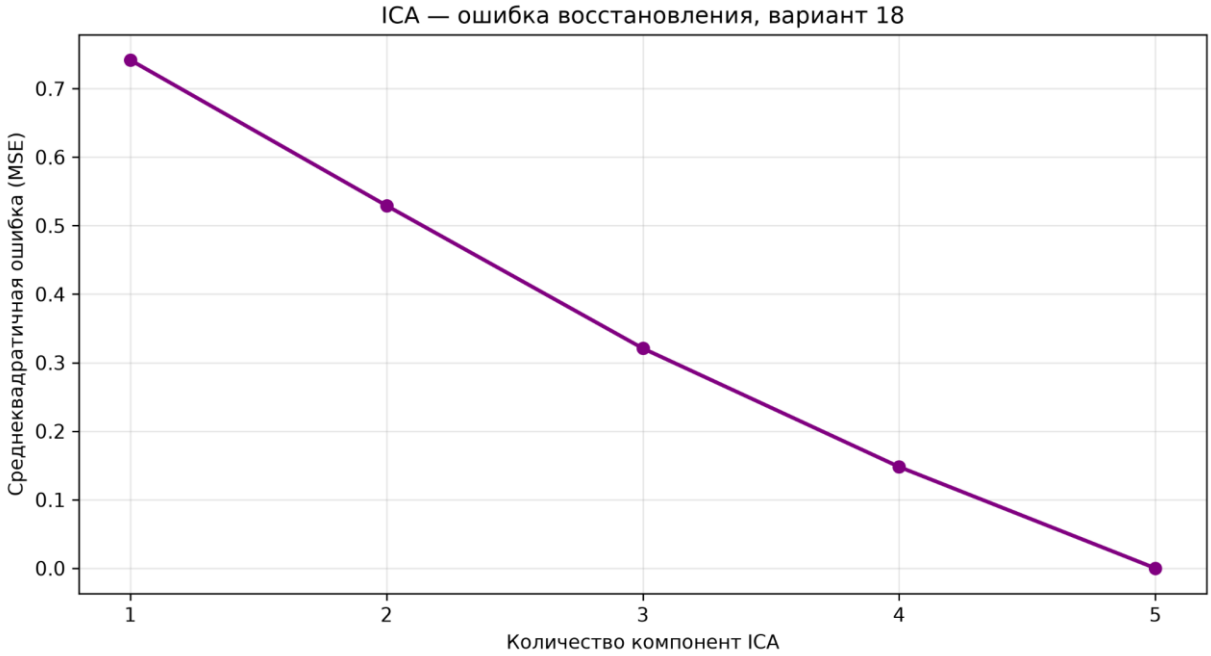


Рисунок 5 — Ошибка восстановления данных методом ICA

Для каждого количества компонент я преобразовал данные, восстановил их обратным преобразованием и вычислил среднеквадратичную ошибку (MSE — Mean Squared Error). График показывает уменьшение ошибки с 0,742 до 0 по мере увеличения числа компонент. При двух компонентах алгоритм не достиг сходимости, поэтому соответствующую оценку я рассматриваю как предварительную. Компоненты ICA не упорядочены по объяснённой дисперсии.

1.6 Сопоставление методов

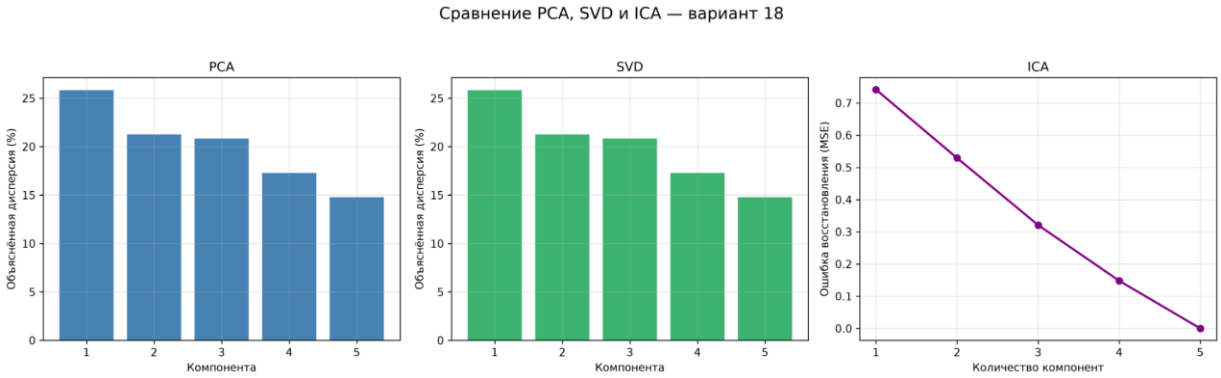


Рисунок 6 — Сравнение показателей PCA, SVD и ICA

Я объединил на одном рисунке показатели PCA, SVD и ICA для сопоставления методов. PCA и SVD демонстрируют одинаковые доли

дисперсии, а ICA — снижение ошибки восстановления. Эти показатели имеют разный смысл, поэтому я не сравнивал их численно как одну метрику.

1.7 Двумерные проекции и направления признаков

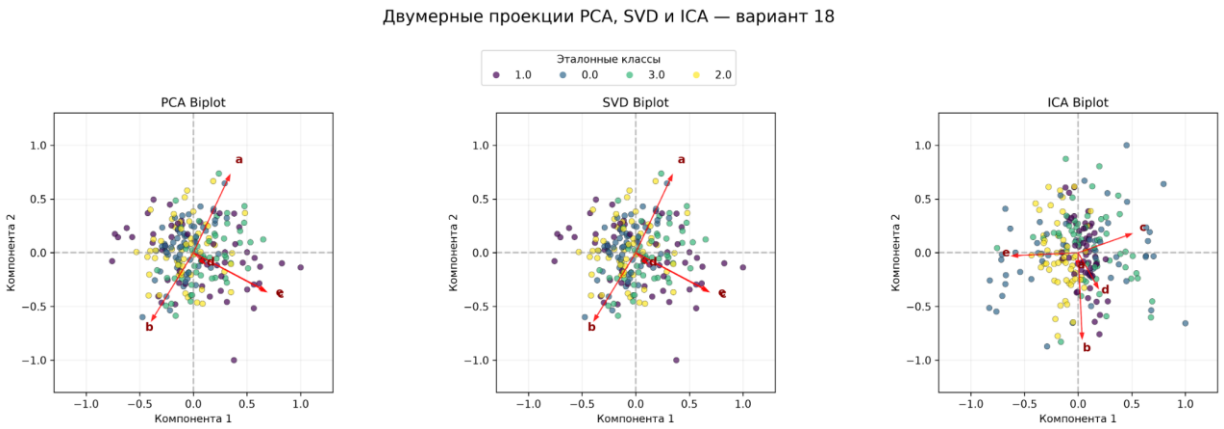


Рисунок 7 — Двумерные проекции и векторы признаков для PCA, SVD и ICA

Я построил проекции наблюдений на первые две рассчитанные компоненты и добавил нормированные направления исходных признаков в виде красных стрелок. Эталонные метки использовал исключительно для окрашивания точек. Проекции PCA и SVD почти совпали; в ICA распределение изменилось. Значительное перекрытие цветов показывает, что две компоненты не обеспечивают полного разделения эталонных классов. Для ICA первые две компоненты выбраны по порядку выдачи алгоритма, а не по рангу значимости.

2 ИССЛЕДОВАНИЕ АЛГОРИТМОВ КЛАСТЕРИЗАЦИИ

2.1 Исходные данные и эталонная структура

Во второй части я исследовал 226 наблюдений по двум признакам. Эталонные метки образуют три класса численностью 77, 75 и 74 объекта. Перед обучением моделей я стандартизировал признаки, чтобы различие масштабов не искажало расстояния.

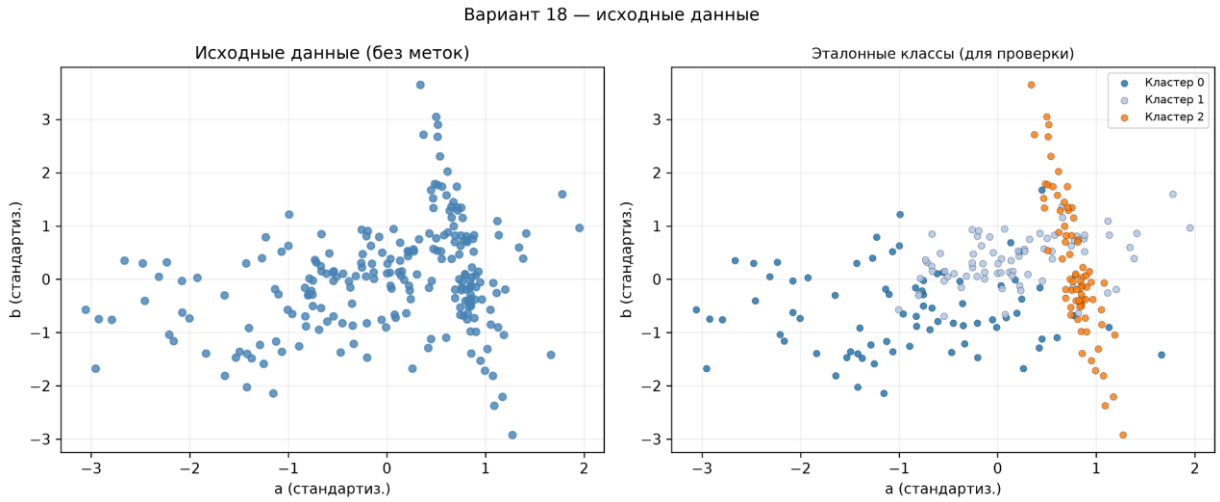


Рисунок 8 — Исходное распределение и эталонные классы

Слева я изобразил наблюдения без меток, справа — те же точки с цветами эталонных классов. График получен функцией scatter() и нужен для оценки пространственной формы групп и последующего сравнения с результатами кластеризации. Я наблюдал вытянутые и частично пересекающиеся группы, что осложняет работу алгоритмов, ориентированных на компактные сферические кластеры.

2.2 Сравнение двенадцати алгоритмов

Я исследовал 12 алгоритмов: K-Means (метод k-средних), Affinity Propagation (распространение сходства), Mean Shift (сдвиг среднего), Spectral Clustering (спектральная кластеризация), Ward (иерархическая кластеризация по критерию Уорда), Agglomerative Clustering (агломеративная кластеризация), DBSCAN (Density-Based Spatial Clustering of Applications with Noise — плотностная пространственная кластеризация приложений с шумом), HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise — иерархическая плотностная кластеризация приложений с шумом), OPTICS (Ordering Points To Identify the Clustering Structure — упорядочение точек для выявления структуры кластеров), Gaussian Mixture (смесь гауссовских распределений), Birch (Balanced Iterative Reducing and Clustering using Hierarchies — сбалансированное итеративное сокращение и

кластеризация с использованием иерархий) и Bisecting K-Means (делящий метод k-средних).

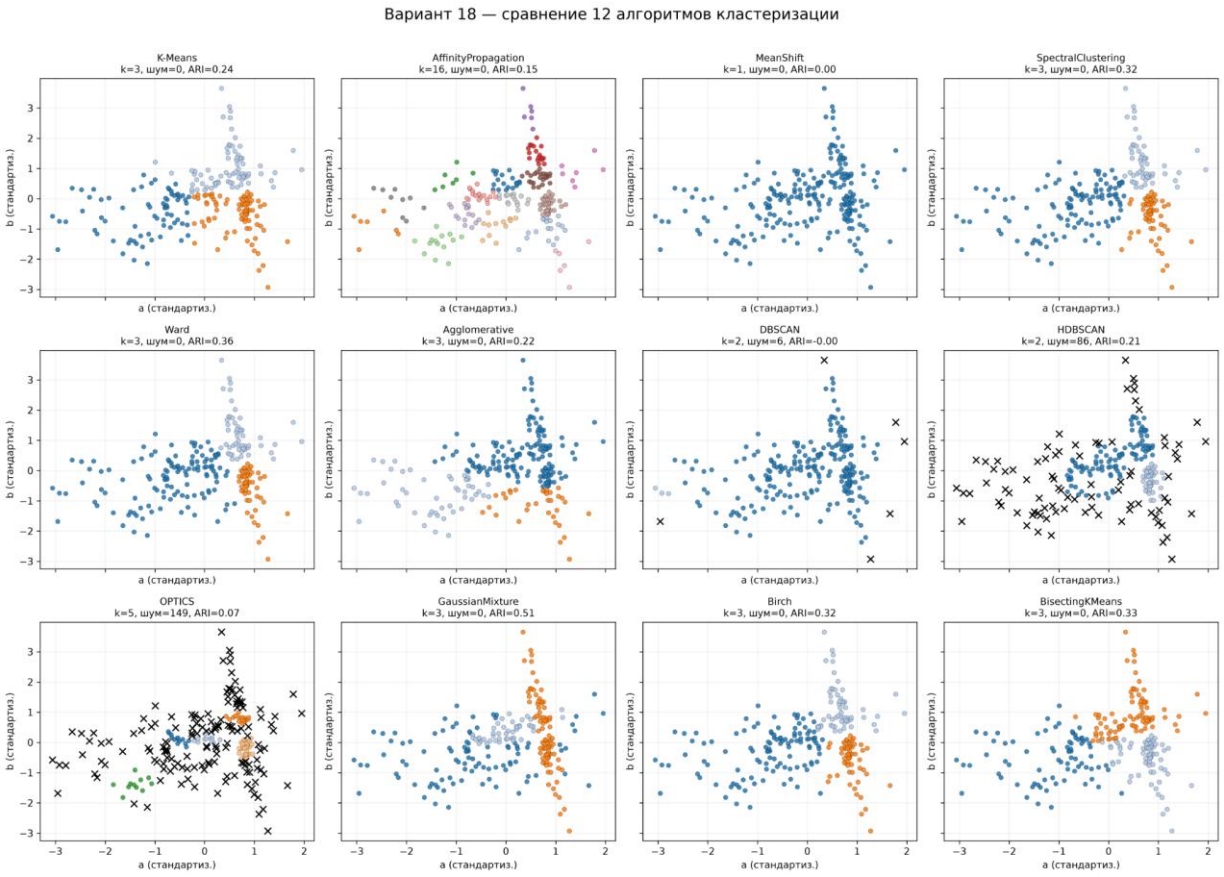


Рисунок 9 — Сравнение результатов двенадцати алгоритмов кластеризации

Для каждого алгоритма я обучил модель на одних и тех же стандартизированных признаках. Цветом показал найденные кластеры, чёрными крестами — шумовые точки. Сравнение 12 панелей позволяет увидеть различия в форме и числе групп. В частности, Gaussian Mixture выделил три группы, близкие к эталону, а Mean Shift объединил все наблюдения в один кластер.

2.3 Выбор числа кластеров для K-Means

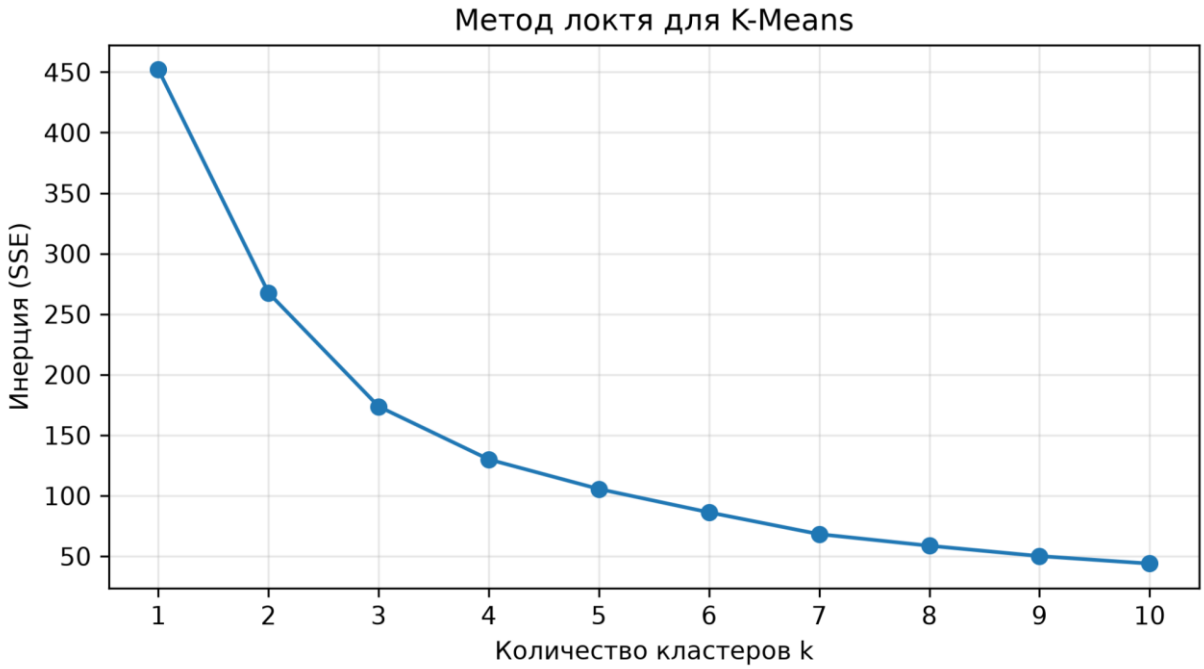


Рисунок 10 — Метод локтя для K-Means

Я последовательно задавал число кластеров от 1 до 10 и рассчитывал инерцию — сумму квадратов расстояний до центров кластеров. На графике снижение инерции становится более плавным примерно после трёх кластеров. Это служит аргументом в пользу выбора трёх групп, хотя метод локтя не даёт строгого доказательства оптимальности.

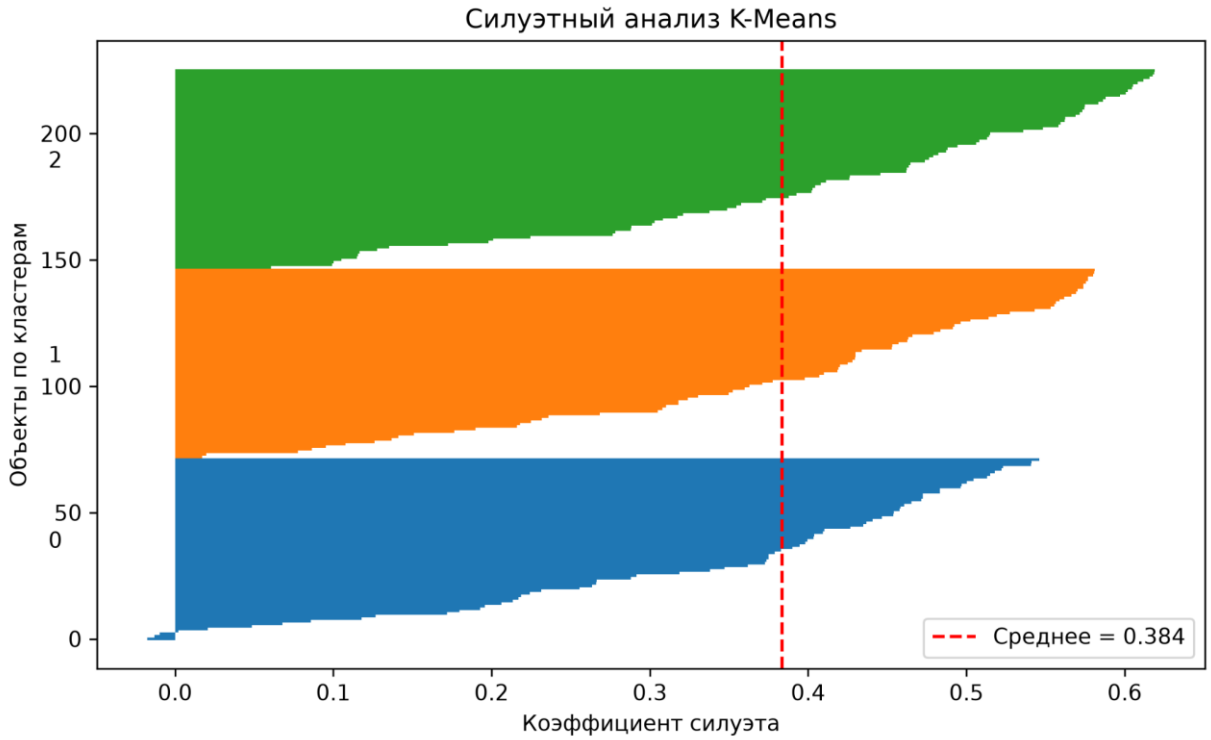


Рисунок 11 — Силуэтный анализ K-Means при трёх кластерах

Для каждого объекта я вычислил коэффициент силуэта, отражающий сходство с собственным кластером по сравнению с ближайшим соседним кластером. Полосы показывают распределение оценок по трём группам; пунктир обозначает среднее значение 0,384. По этому рисунку я оценил умеренную разделённость кластеров K-Means.

2.4 Иерархическая кластеризация

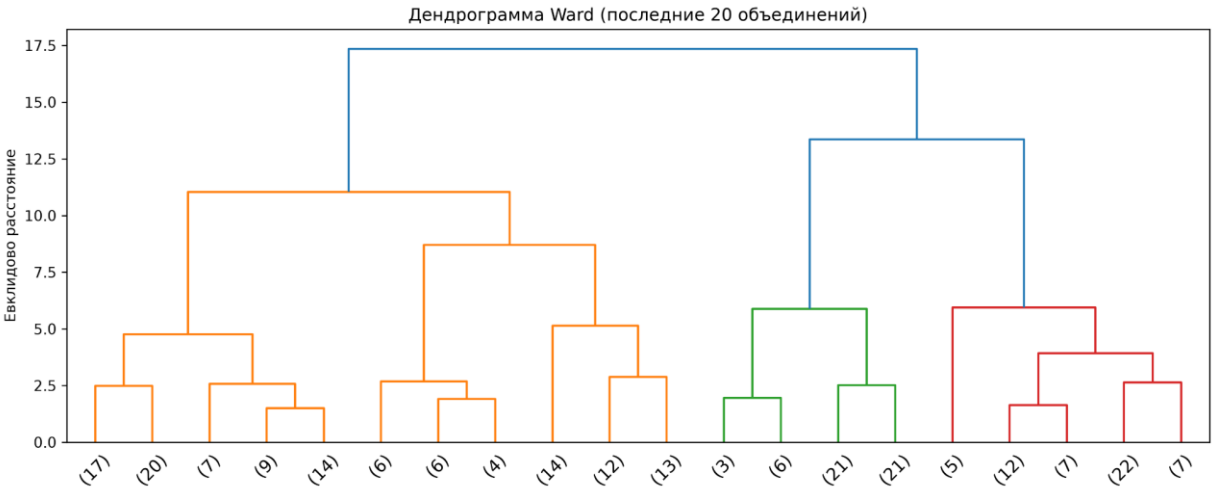


Рисунок 12 — Дендрограмма метода Ward

Я построил дендрограмму по критерию Ward и для читаемости показал последние 20 объединений. Высота ветвей отражает расстояние слияния групп. Рисунок помогает определить крупные ветви и возможное число кластеров. Я использовал его для дополнительной проверки иерархической структуры данных.

2.5 Выявление шума и выбросов

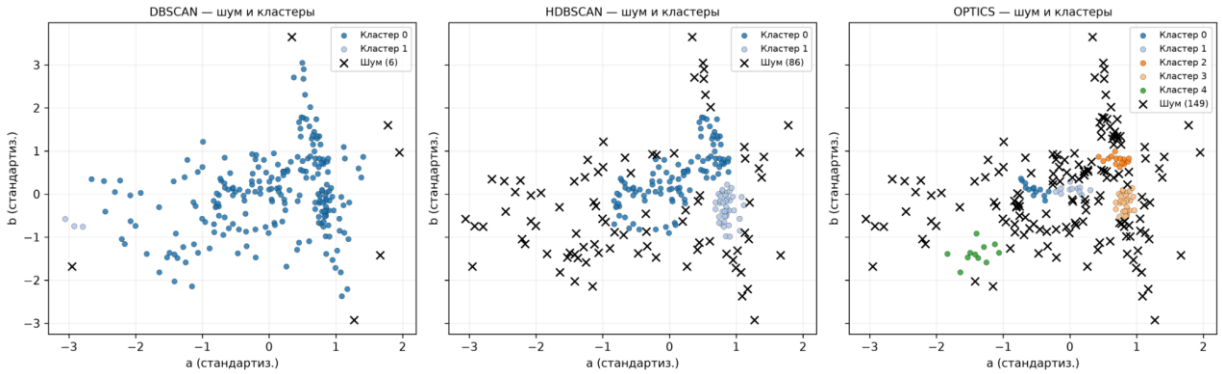


Рисунок 13 — Кластеры и шум по результатам DBSCAN, HDBSCAN и OPTICS

Я сопоставил результаты трёх плотностных алгоритмов. Метку −1 изобразил чёрными крестами как кандидатов в выбросы, а не как доказанные ошибки измерений. При выбранных параметрах DBSCAN отметил 6 шумовых точек, HDBSCAN — 86, OPTICS — 149. Таким образом, я выявил высокую чувствительность результатов к параметрам и локальной плотности данных.

2.6 Количественная оценка качества

Для проверки соответствия эталонным классам я рассчитал скорректированный индекс Рэнда (ARI — Adjusted Rand Index) и нормализованную взаимную информацию (NMI — Normalized Mutual Information). Для внутренней оценки разделения кластеров использовал коэффициент силуэта (Silhouette Score). В таблице также указал количество кластеров и шумовых наблюдений.

Таблица 1 — Результаты кластеризации варианта 18

Алгоритм	Кластеров	Шум	Silhouette	ARI	NMI
GaussianMixture	3	0	0,055	0,509	0,487

Ward	3	0	0,333	0,357	0,422
BisectingKMeans	3	0	0,374	0,328	0,342
SpectralClustering	3	0	0,353	0,320	0,374
Birch	3	0	0,356	0,320	0,366
K-Means	3	0	0,384	0,245	0,273
Agglomerative	3	0	0,345	0,223	0,290
HDBSCAN	2	86	0,329	0,215	0,232
AffinityPropagation	16	0	0,427	0,154	0,365
OPTICS	5	149	0,679	0,067	0,242
MeanShift	1	0	—	0,000	0,000
DBSCAN	2	6	0,431	-0,001	0,022

По таблице я установил, что Gaussian Mixture получил наибольшие значения ARI = 0,509 и NMI = 0,487, выделив три кластера без шумовых меток. Следом расположились Ward (ARI = 0,357) и Bisecting K-Means (ARI = 0,328). Хотя некоторые методы показали более высокий коэффициент силуэта, он не означает лучшего совпадения с эталоном. Поэтому для данной задачи я выбрал Gaussian Mixture по внешним метрикам.

ВЫВОД

В ходе выполнения лабораторной работы я достиг поставленной цели: исследовал методы снижения размерности и сравнил 12 алгоритмов кластеризации на данных варианта 18. Сначала я изучил корреляции и попарные распределения пяти признаков. Матрица корреляций показала преимущественно слабые линейные связи, а матрица разброса позволила заметить нелинейную структуру отдельных пар признаков. Затем я применил PCA, SVD и ICA, оценил характеристики компонент и построил двумерные проекции. Я установил, что первые две компоненты PCA и SVD сохраняют 47,08 % дисперсии, а для превышения порога 80 % необходимы четыре компоненты. В ICA ошибка восстановления уменьшалась при увеличении числа компонент; при двух компонентах я отметил предупреждение о несходимости.

Во второй части я изучил распределение 226 объектов, выполнил кластеризацию 12 методами, построил сравнительные графики, использовал метод локтя, силуэтный анализ и дендрограмму, а также исследовал шумовые точки плотностных алгоритмов. Сравнив результаты с эталонными метками, я установил, что лучшего соответствия достиг Gaussian Mixture (ARI = 0,509; NMI = 0,487). Следовательно, для исследованного варианта и выбранных параметров я считаю его наиболее подходящим из рассмотренных алгоритмов по критерию совпадения с эталонными классами. Таким образом, все поставленные задачи я выполнил.